

Análise Exploratória de Dados - Avaliação Presencial (Gabarito) - 2026/01

Prof. Hugo Carvalho

25/06/2026

Questão 1: (2,5) Analisando a fórmula para o cálculo de $\text{cor}(x, y)$, façamos a expansão primeiro do numerador:

$$\begin{aligned}\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) &= \frac{1}{n} \sum_{i=1}^n (x_i y_i - x_i \bar{y} - y_i \bar{x} + \bar{x} \bar{y}) \\ &= \frac{1}{n} \sum_{i=1}^n (x_i y_i) - \bar{x} \bar{y} - \bar{x} \bar{y} + \bar{x} \bar{y} \\ &= \frac{1}{n} \left[\sum_{i=1}^n (x_i y_i) - n \bar{x} \bar{y} \right],\end{aligned}$$

algo bem próximo com o numerador da nova expressão, a menos do fator multiplicativo $1/n$. Um procedimento análogo de expansão (que foi passado como exercício nas aulas presenciais) nos dará que

$$\text{dp}(x) = \sqrt{\frac{1}{n} \left[\sum_{i=1}^n (x_i^2) - n \bar{x}^2 \right]}.$$

Analogamente, vale resultado semelhante para y . Substituindo as novas expressões para o numerador e denominador na fórmula para $\text{cor}(x, y)$, obtemos o resultado desejado.

Questão 2:

- a) **(1,0)** Seguindo as instruções da questão e conforme feito em sala de aula, a tabela de contingência esperada é dada por

	Hipertenso	Não hipertenso	Total
Pratica atividade física	20	30	50
Não pratica atividade física	20	30	50
Total	40	60	100

Repare que os valores das células são dados por 40% de 50 ou 60% de 50 (ou, analogamente, 50% de 40 ou 50% de 60), exatamente o que ocorre com uma tabela de contingência esperada se não há relação entre as variáveis.

- b) **(1,0)** A estatística χ^2 é dada por:

$$\chi^2 = \frac{(10 - 20)^2}{20} + \frac{(40 - 30)^2}{30} + \frac{(30 - 20)^2}{20} + \frac{(20 - 30)^2}{30} \approx 16,6.$$

- c) O valor de 16,6 é bem maior do que 3,84, de modo que a hipótese de independência pode ser rejeitada.

Questão 3: (2,5) Ordenando a série de observações, temos que: 0, 0, 0, 1, 1, 1, 1, 2, 2, 2, 2, 3, 3, 4, 7. Como temos 15 observações, a mediana será a observação que ocupa a posição central, de índice 8, sendo, portanto, igual a 2. O primeiro quartil é a mediana das observações que antecedem a mediana, ou seja, a mediana do conjunto 0, 0, 0, 1, 1, 1, 1, que é igual a 1 por um raciocínio análogo. Da mesma forma, o terceiro quartil será a mediana do conjunto que está após a mediana, a saber, 2, 2, 2, 3, 3, 4, 7, que é 3. Assim, a distância interquartil é dada por $DIQ = 3 - 1 = 2$, o limite inferior é dado por $LI = Q1 - 1,5 \times DIQ = -2$ e o limite superior é dado por $LS = Q3 + 1,5 \times DIQ = 6$. Dessa forma, o conjunto de dados tem uma observação discrepante, que é o 7. Veja na próxima página o boxplot com essas estatísticas calculadas.

Questão 4:

- a) **(1,5)** Os números não parecem ser de fato aleatórios, pois caso o fossem, esperaríamos observar aproximadamente a mesma frequência absoluta para todos os números. Mais especificamente, como o usuário solicitou 10.000 números, esperaríamos ver cada um sendo sorteado aproximadamente 100 vezes. O gráfico da questão mostra uma clara preferência por números ímpares, e não sorteia praticamente nenhum múltiplo de 5 ou 10. Dessa forma, não se pode afirmar que os números gerados seguem o padrão solicitado pelo usuário.
- b) **(1,0)** Conforme apontado ao final do item anterior, a LLM não seguiu o comando dado pelo usuário, uma vez que gerou números com alguma “preferência”, contradizendo a solicitação de aleatoriedade. Dessa forma, podemos concluir que deve-se ter cuidado ao analisar informações retornadas por LLM, pois nem sempre a máquina irá gerar uma resposta verossímil ou compatível com o que foi solicitado, necessando, portanto, de uma minuciosa inspeção humana posteriormente.

