

Análise Exploratória de Dados - Avaliação Presencial - 2026/01

Prof. Hugo Carvalho

25/06/2026

Questão 1: Sejam $\{x_1, \dots, x_n\}$ e $\{y_1, \dots, y_n\}$ dois conjuntos de observações de variáveis quantitativas. Defina o *coeficiente de correlação linear* entre x e y como

$$\text{cor}(x, y) = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\text{dp}(x)\text{dp}(y)},$$

onde, para relembrar,

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad \text{e} \quad \text{dp}(x) = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2},$$

sendo tais quantidades definidas analogamente para y . Mostre que uma outra forma de calcular $\text{cor}(x, y)$ é dada por

$$\text{cor}(x, y) = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sqrt{\sum_{i=1}^n x_i^2 - n \bar{x}^2} \sqrt{\sum_{i=1}^n y_i^2 - n \bar{y}^2}}.$$

Questão 2: Uma pesquisa investigou se há associação entre o hábito de praticar atividade física regularmente e a presença de hipertensão em um grupo de 100 pessoas. A tabela de contingência dos dados coletados é a seguinte:

	Hipertenso	Não hipertenso	Total
Pratica atividade física	10	40	50
Não pratica atividade física	30	20	50
Total	40	60	100

Com base nisso, faça o que se pede abaixo.

- Monte a tabela de contingência esperada, ou seja, assumindo que não há relação entre as variáveis de interesse mas mantendo as mesmas contagens marginais (indicada na linha e coluna “Total”).
- Para comparar sistematicamente ambas as tabelas, calcule a estatística χ^2 , dada por

$$\chi^2 = \sum_i \sum_j \frac{(o_{ij} - e_{ij})^2}{e_{ij}},$$


onde i varre as linhas e j varre as colunas, de modo que o_{ij} e e_{ij} são, respectivamente, os valores nas células das tabelas observada e hipotética construída no item a).

- Conforme será demonstrado em disciplinas mais à frente no curso, um “bom valor máximo” para a estatística χ^2 , nesse cenário, é 3,84. Ou seja, para estatísticas abaixo de tal valor não é possível rejeitar a hipótese de que as variáveis são independentes. Compare o valor calculado no item b) com tal quantidade, e conclua se a hipótese da independência pode ou não ser rejeitada.

Questão 3: Ao longo de um campeonato de quinze jogos, determinado time de futebol marcou a seguinte quantidade de gols a cada partida: 2, 1, 0, 3, 2, 1, 4, 2, 0, 1, 3, 2, 1, 7, 0. Faça e discuta um *box-plot* desses dados, calculando explicitamente as informações necessárias para montar o gráfico.

– QUESTÃO 4 NO VERSO DA PÁGINA –

Questão 4: Um usuário da rede social Reddit pediu para uma LLM (modelo de linguagem em larga escala, da sigla em Inglês *Large Language Model*), no caso o ChatGPT, gerar 10.000 números aleatórios entre 0 e 100. A figura abaixo mostra um gráfico de barras da frequência absoluta dos números retornados pela LLM. Com base nisso, responda às questões abaixo.



- Os números retornados pela LLM parecem ser de fato aleatórios? Caso você ache que não, como você acha que seria o gráfico de barras de uma amostra com total aleatoriedade? Justifique as suas respostas.
- O que você pode dizer, detalhadamente, sobre a capacidade de tal LLM seguir o comando dado pelo usuário? Com base nisso, o que você pode inferir sobre informações retornadas por LLMs, de modo geral?